Seminário Java + GPU

Paulina Rehbein

Programação Paralela Heterogênea

Pontifícia Universidade Católica do Rio Grande do Sul - PUCRS

Porto Alegre – RS – Brasil

Novembro - 2025

PUCRS

Tópicos

- JCuda
- matrix-multiplication
- Comparação desempenho

JCuda

- O JCuda é um wrapper JNI (Java Native Interface) que expõe praticamente as mesmas funções da API CUDA, mas acessíveis via Java.
- Faz o espelho das abstrações do CUDA através de objetos e métodos Java que chamam código nativo C/C++ por baixo.
- Ele serve como a plataforma comum para diversas outras bibliotecas de aceleração GPU baseadas em CUDA, como JCublas, JCufft, JCurand, e JCusparse.

JCuda - Runtime API

- A principal aplicação dos bindings do JCuda Runtime é a interação com bibliotecas existentes construídas sobre a CUDA Runtime API
- É usada para interagir com bibliotecas como JCublas, JCufft, JCurand, e JCusparse.

JCuda - Driver API

- O uso principal dos bindings do JCuda Driver é carregar módulos PTX e executar kernels a partir de uma aplicação Java
- O Driver API permite inicializar o driver, criar contextos, carregar arquivos PTX, obter um handle para a função do kernel (cuModuleGetFunction) e lançar o kernel (cuLaunchKernel).
- Para garantir que o kernel possa ser acessado pelo seu nome na API de Driver, a função do kernel deve ser declarada como extern "C" no código CUDA

JCuda - Pointer

- Referências Java não são adequadas para emular ponteiros nativos, pois não permitem aritmética de ponteiros e não podem ser passadas diretamente para bibliotecas nativas.
- Por não existir ponteiros reais em Java o JCuda introduziu a classe Pointer que pode ser tratada de forma semelhante a um ponteiro void* em C
- Um Pointer pode ser criado instanciando um novo Pointer (que inicialmente será NULL).

```
Pointer pointer = Pointer.to(new int[]{N});
```

JCuda – Abstrações

CUDA C/C++	JCuda	Descrição
`cudaSetDevice(int device)`	`JCuda.cudaSetDevice(int)`	Define qual GPU será utilizada pelo programa.
`cudaGetDeviceProperties(cudaDeviceProp *prop, int device)`	`JCuda.cudaGetDeviceProperties(cudaDeviceProp, int)`	Obtém as propriedades (nome, memória, SMs etc.) da GPU.
`cuInit(0)`	`JCudaDriver.cuInit(0)`	Inicializa a API Driver e prepara o uso do CUDA.
`cuDeviceGet(CUdevice device, int ordinal)`	`JCudaDriver.cuDeviceGet(CUdevice, int)`	Obtém uma referência a uma GPU específica.
`cuCtxCreate(CUcontext ctx, unsigned int flags, CUdevice device)`	`JCudaDriver.cuCtxCreate(CUcontext, int, CUdevice)`	Cria um contexto CUDA associado a um dispositivo (essencial na Driver API).
`CUdeviceptr`	`Pointer` (classe `jcuda.Pointer`)	Representa um ponteiro para memória no dispositivo (GPU).

JCuda – Abstrações

CUDA C/C++	JCuda	Descrição
`cudaLaunchKernel()` / `kernel<<<grid, block>>>(...)`	`JCudaDriver.cuLaunchKernel(function, gridX, gridY, gridZ, blockX, blockY, blockZ, sharedMem, stream, params, null)`	Lança um kernel na GPU.
`cudaMalloc(void **devPtr, size_t size)`	`JCuda.cudaMalloc(Pointer, long)`	Aloca memória na GPU (Runtime API).
`cudaFree(void *devPtr)`	`JCuda.cudaFree(Pointer)`	Libera memória alocada na GPU (Runtime API).
`cudaMemcpy(void *dst, void *src, size_t size, cudaMemcpyKind kind)`	`JCuda.cudaMemcpy(Pointer dst, Pointer src, long size, int kind)`	Copia dados entre memória host e device (sincrono).
`cuMemcpyHtoD(CUdeviceptr dst, Pointer src, long size)`	`JCudaDriver.cuMemcpyHtoD(CUdeviceptr, Pointer, long)`	Copia do host → device.
`cuMemcpyDtoH(Pointer dst, CUdeviceptr src, long size)`	`JCudaDriver.cuMemcpyDtoH(Pointer, CUdeviceptr, long)`	Copia do device → host.
`__global__ void kernel(...)`	Kernel definido em `.cu` e compilado para `.ptx`, carregado via `cuModuleGetFunction()`	Função que será executada na GPU.

JCuda – matrix multiplication

- https://github.com/PaulinaEster/jcuda-samples/tree/master/seminario-gpu

JCuda – matrix multiplication Passo 1

// passo 1 - principais variáveis

```
public class JCudaMatrixMultiplication {

    public static void main(String args[]) throws IOException

    {
      Config.setupCommon();
      int N = Config.getWorkload().getN();
      int[][] matrix1 = new int[N][N];
      int[][] matrix2 = new int[N][N];
      int[][] matrix3 = new int[N][N];
      MatrixMultiplicationUtils.initialization(matrix1, matrix2, matrix3);
      int[] matrix1Linear = new int[N*N];
      int[] matrix2Linear = new int[N*N];
      int[] matrix3Linear = new int[N*N];
      linearization(matrix1, matrix2, matrix3, matrix1Linear, matrix2Linear, matrix3Linear);
```

JCuda – matrix multiplication

```
// passo 1 - principais variáveis
// passo 2 - cria PTX e inicializa JCuda Driver
// Enable exceptions and omit all subsequent error checks
JCudaDriver.setExceptionsEnabled(true);
// Create the PTX file by calling the NVCC
String ptxFileName = JCudaSamplesUtils.preparePtxFile(
"src/main/resources/kernels/JCudaMatrixMultiplicationKernel.cu");
// Initialize the driver
cuInit(0);
CUdevice device = new CUdevice();
cuDeviceGet(device, 0);
```

JCuda – matrix multiplication

```
// passo 3 - Cria contexto para o device
CUcontext context = new CUcontext();
cuCtxCreate(context, 0, device);
int[] maxThreadsPerBlock = new int[1];
byte[] nameBytes = new byte[1024];
JCudaDriver.cuDeviceGetAttribute(
    maxThreadsPerBlock,    CUdevice_attribute.CU_DEVICE_ATTRIBUTE_MAX_THREADS
    _PER_BLOCK,
    device);
JCudaDriver.cuDeviceGetName(nameBytes, nameBytes.length, device);
```

```
// Load the ptx file.
CUmodule module = new CUmodule();
cuModuleLoad(module, ptxFileName);
// Obtain a function pointer to the
    "matrix_multiplication" function.
CUfunction function = new CUfunction();
cuModuleGetFunction(function, module,
 "matrix_multiplication");
```

JCuda – matrix multiplication

```
// passo 4 - Criar objetos na memória
CUdeviceptr deviceMatrix1 = new CUdeviceptr();
CUdeviceptr deviceMatrix2 = new CUdeviceptr();
CUdeviceptr deviceMatrix3 = new CUdeviceptr();
// Alocação de dados para o device
cuMemAlloc(deviceMatrix1, N * N * Sizeof.INT);
cuMemAlloc(deviceMatrix2, N * N * Sizeof.INT);
cuMemAlloc(deviceMatrix3, N * N * Sizeof.INT);
```

```
// Tranferencia de dados para a memoria do device
cuMemcpyHtoD(deviceMatrix1,
    Pointer.to(matrix1Linear),
    N * N * Sizeof.INT);
cuMemcpyHtoD(deviceMatrix2,
    Pointer.to(matrix2Linear),
    N * N * Sizeof.INT);
cuMemcpyHtoD(deviceMatrix3,
    Pointer.to(matrix3Linear),
    N * N * Sizeof.INT);
```

JCuda – matrix multiplication

```
// passo 5 - Cria ponteiro para os parametros do kernel
// Set up the kernel parameters: A pointer to an array
// of pointers which point to the actual values.
Pointer kernelParameters = Pointer.to(
    Pointer.to(deviceMatrix1),
    Pointer.to(deviceMatrix2),
    Pointer.to(deviceMatrix3),
    Pointer.to(new int[]{N})
);
```

JCuda – matrix multiplication

```
// passo 1 - principais variáveis
// passo 2 - cria PTX e inicializa JCuda Driver
// passo 3 - Cria contexto Cuda
// passo 4 - criar objetos na memória
// passo 5 - Cria ponteiro para os parametros do kernel
// passo 6 – executa o kernel
// Call the kernel function.
int threads = maxThreadsPerBlock[0];
int blockSize = (int)Math.ceil((double)(N * N) / threads);
```

```
cuLaunchKernel(function,
        blockSize, 1, 1, // Grid dimension
        threads, 1, 1, // Block dimension
        0, null, // Shared memory size and stream
        kernelParameters, null // Kernel- and extra
            parameters
);
cuCtxSynchronize();
```

JCuda – matrix multiplication

```
// passo 1 - principais variáveis
// passo 2 - cria PTX e inicializa JCuda Driver
// passo 3 - Cria contexto Cuda
// passo 4 - criar objetos na memória
// passo 5 - Cria ptr para os parametros do kernel
// passo 6 – executa o kernel
// passo 7 - copiar os resultados para o host
cuMemcpyDtoH(
    Pointer.to(matrix3Linear),
    deviceMatrix3,
    N * N * Sizeof.FLOAT
);
```

JCudaMatrixMultiplicationKernel.cu

```
extern "C"

__global__ void matrix_multiplication(int* matrix1,
    int* matrix2,
    int* matrix3,
    int N
    ){
        int tid = blockIdx.x * blockDim.x + threadIdx.x;
        if(tid > (N * N)) {return;}
        int j = (tid / N) % N; // altura largura
        int k = tid % N;
        for(int i = 0; i < N; i++){
            matrix3[j + k * N] += matrix1[j + i * N] * matrix2[i + k * N];
        }
}
```

Comparação JCuda x CUDA

- SO: Debian 6.1.148-1
- Kernel Linux: Linux slurm-head 6.1.0-39-amd64
- CPU: Intel(R) Xeon(R) CPU E5-2620 0 @ 2.00GHz
- GPU: NVIDIA TITAN Xp
- Versões de Software:
    - Compilador: GCC 11.3 G++ 11.3
    - CUDA: 11.8
    - JDK: 8
    - Maven: 3.9

Executado multiplicação de matrizes de dimensão 4096 x 4096 Workload G

Comparação JCuda x CUDA

- Tempo médio serial em C 318.261150s
- Tempo médio serial JAVA 395.117114s
- Tempo médio CUDA 26.666288s
- Tempo médio JCuda 31.517022s

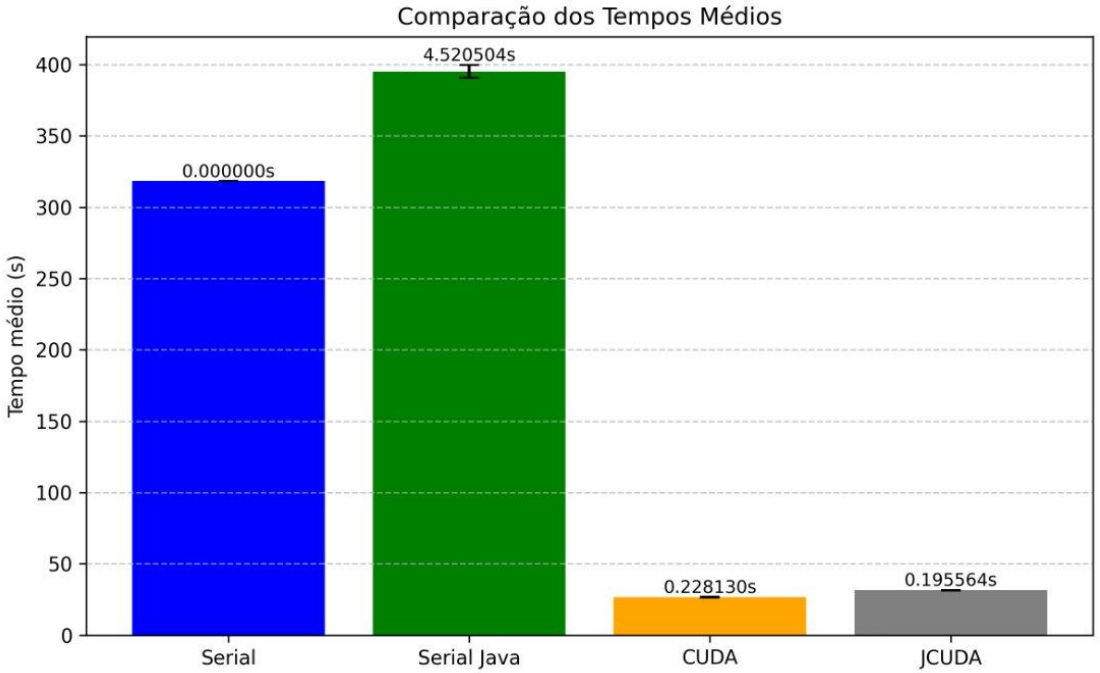

Comparação JCuda x CUDA

O tempo de execução maior na versão com JCuda ocorre porque as chamadas da API Java funcionam como uma camada de ligação (binding) sobre o código nativo em C/C++ e o Java não possui acesso direto à GPU, dependendo dessa conversão para utiliza-lá.

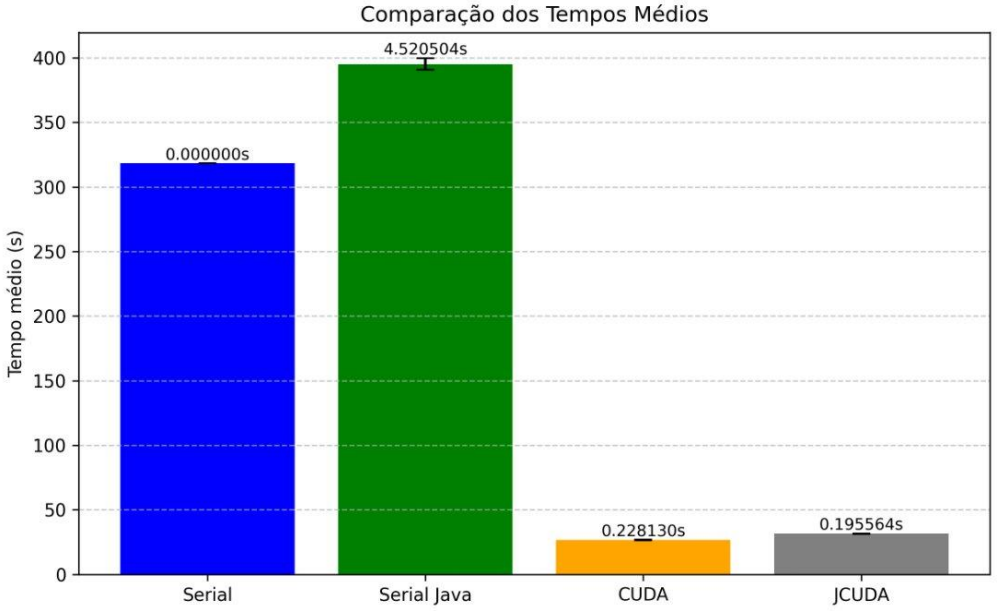

Comparação JCuda x CUDA

- Speedup
- Speedup CUDA 11.93x
- Speedup JCuda 10.10x

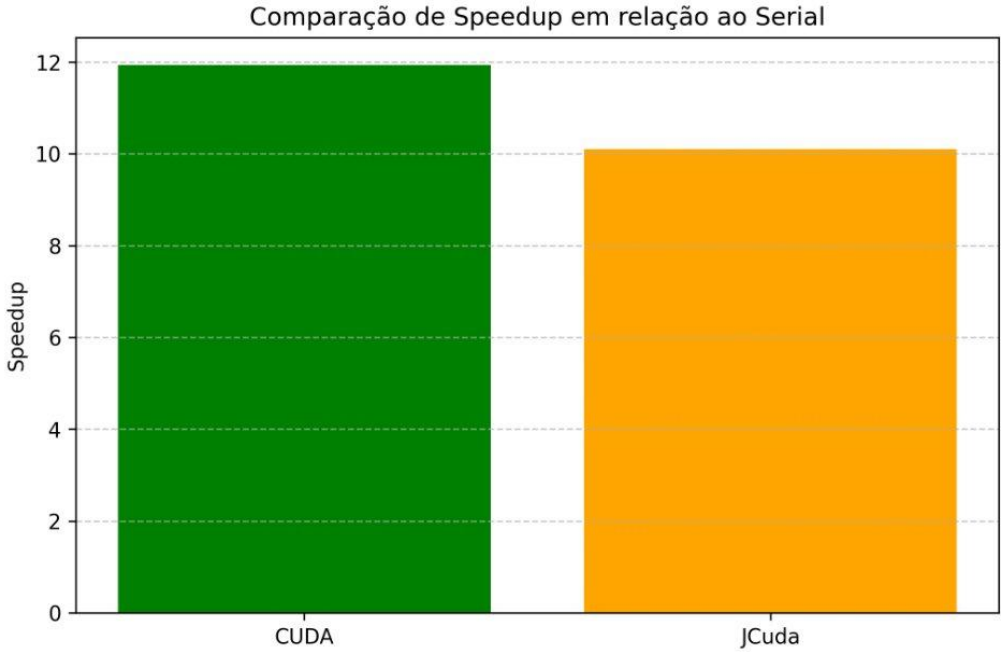

Comparação JCuda x CUDA

- Tempo por etapa da execução

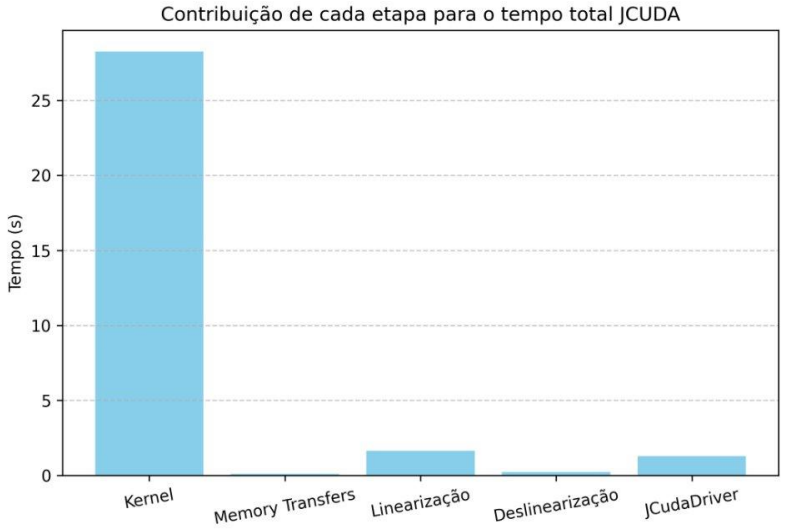

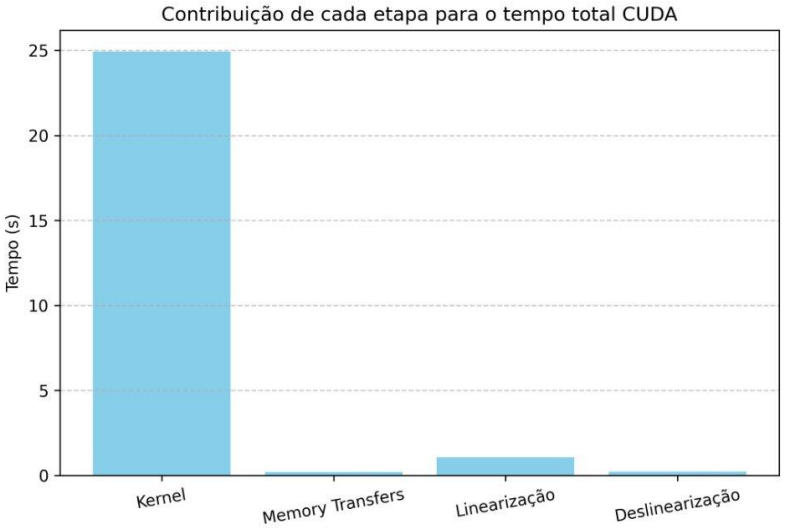

Referências

- http://www.jcuda.org/jcuda/JCuda.html#Features
- https://github.com/jcuda/jcuda-samples
- https://mvnrepository.com/artifact/org.jcuda/jcuda